

版本 1.12 | 当前投票算法逐项解剖

日期：2026-09-16。以下均指已运行的 D0-Real 算法；其输入是 1.11 文档的手工描述子，不是 VACE Q/K。

1. 检索先做什么

对每帧的每个查询 Token q ，构建参考库：**F** 模式为首帧 1296 个 Token；**FL** 模式为首帧与尾帧共 2592 个 Token。先与库内**全部** Token 计算相似度，而不是只与附近或一个运动槽计算。特征为两个 RootSIFT 加 RGB/Lab 局部颜色的 265 维单位向量；分数为归一化向量的**内积/余弦相似度** $s(q,r)=d_q \cdot d_r$ 。RGB 不是逐像素差，也没有使用 VAE 潜空间高维张量。排序取 Top-16，留存参考端点、Token ID、原分数；主要交互与 P5 稀疏候选限制到 Top-8。[本地描述子和检索实现](#)、[候选数组生成](#)

所谓“原对应像素-置信度表”需要拆开：P0 存的是**外观相似度 Top-16**，不能称为真实对应像素概率；由 Top-16 分数以温度 **0.012** softmax 得到相对权重，并计算 Top1/Top2 差距与熵。softmax 权重只在这 16 个候选之间归一，不是经过真实对应标签校准的正确率。热力图的全参考库余弦分数又是网页查询时从保存的描述子计算的，与已截断的候选权重是两套数值。[候选统计](#)、[网页热力图计算](#)

2. 外观候选如何投票成运动槽

参考候选 r 与查询 q 的 (x,y) 差、查询帧在窗口内的相对时间 α 构成一条**假设位移/速度**：首帧候选近似 $(q-r)/\alpha$ ，尾帧候选近似 $(r-q)/(1-\alpha)$ ；靠端点极短时间差的速度不稳定，以 **geometry_reliability** 降权。每条票的强度来自外观 softmax 权重、查询 Token 的纹理分数、Top-16 熵的清晰度及时间基线可靠性。这是“候选对应假设投票”，不是先把全图色块直接聚类。[候选几何和票权](#)

每帧把这些**全图 Token 的 Top-16 候选票**一起拟合固定 **6 个运动槽**，做 10 次软 EM：

- **H0** 槽模型只有二维平移 (v_x, v_y) ；
- **H1** 槽模型是 $v(p)=a \cdot p+(v_x, v_y)$ ，多一个以归一化图像中心位置 p 为变量的统一 scale-rate a ，近似透视缩放中的局部径向场，**不是完整透视投影、深度或遮挡模型**。

EM 按速度残差给每条候选票对 6 槽的 softmax 责任，再按票权重拟合各槽参数。每帧从当帧票重新估计，随后用 Hungarian 参数代价与前帧槽编号对齐，可做参数平滑。编号连续只是模型参数对齐，不等于物体身份被准确追踪。[槽拟合代码](#)

槽个数有固定限制 6；槽大小没有最小/最大 Token 数、连通区域、质量或面积限制。软概率中一个 Token 可以同时属于多个槽（6 槽概率和为 1）；网页白边界与视频着色用 **argmax** 给它一个硬编号，拒绝 Token 则不进入白边界。一个槽可跨多个不相连物体；多个同运动物体也会合并。这个设计符合“运动假设”而非“物体实例”。若以后希望一个槽尽量对应一个物体，需另外考虑连通性、外观/深度边界、实例数自适应与槽面积先验；强行规定大小也可能把真实大背景或小物体切错，不能直接加固定阈值。

3. 票如何反馈候选、置信度与拒绝

EM 后，每条候选的残差拟合度、周围 8 邻域的颜色边缘感知槽概率、前帧槽概率经相邻光流变形后的时间先验，以及槽总体质量，分别以 log 项加到原相似度 logits，再 softmax 重新给候选权重。**P1**：H0，无空间/时间/拒绝；**P2**：H1；**P3**：H1+空间；**P4**：H1+空间+时间；**P5**：P4+拒绝+稀疏 mask。时间先验用 **DIS 光流从真实当前帧和前一帧计算**，这是离线真实视频条件；未来只有首帧的生成初期不能照用这条真实帧光流。**P1–P5 生效参数**、[时间先验读取](#)、[DIS 光流计算](#)

当前网页的 **confidence** 是一条**人工组合分数**： $0.24 \times \text{最高候选权重} + 0.20 \times (1 - \text{候选熵}) + 0.20 \times \text{运动残差拟合} + 0.16 \times \text{空间一致} + 0.20 \times \text{最高外观分数强度}$ ，再乘 $0.25 + 0.75 \times \text{纹理分数}$ ，截到 $[0, 1]$ 。

$\text{reject_probability} = 1 - \text{confidence}$ ，**不是基于数据标签训练/校准的概率**。P5 若 $\text{confidence} < 0.18$ 则拒绝，所有稀疏候选 mask 为 false；不拒绝时只在原序 Top-8 内筛出重新加权后 $\text{weight} \geq 0.035$ 的候选，至少选择 Top-8 中一个最大者。mask 是保存的布尔候选表，**没有实际接入 VACE 的 Value/attention**。[组合分数与稀疏门控](#)

首帧 F/FL 查询首帧自己、FL 尾帧查询尾帧自己时，代码会强制自匹配候选权重和置信度为 1；这些端点查询不能作为运动追踪精度证据。一般当前帧的候选没有手工预置正确位置，但受外观、运动模型及真实相邻帧时间先验影响。[端点自匹配代码](#)

4. 这是不是当前查询技术的最佳实践

“全库余弦 Top-K $\rightarrow$ 多候选运动一致性 $\rightarrow$ 无匹配/遮挡处理”是合理的**可解释基线**，但不存在对所有视频、所有目标通用的“最佳实践”。手工 SIFT+颜色在纹理、尺度、遮挡与重复图案上有已知局限；当前置信度未校准，运动槽数固定，H1 也只是简化缩放。更先进的方法根据任务使用不同信息：LoFTR 的两图上下文特征与粗到细密集匹配旨在处理低纹理区域；TAPIR 的逐帧匹配加时间细化并估计位置不确定性/遮挡；CoTracker 联合跟踪很多点，利用共同轨迹强化遮挡处理；DINO-Tracker 使用语义特征加视频内适配。这些各有训练数据和成本，不可直接声称一定替换 VACE Token 更好。[LoFTR 原论文](#)、[TAPIR 原论文](#)、[CoTracker 原项目](#)、[DINO-Tracker 原项目](#)

与本项目目标直接有关的优化工作，按依赖顺序是：

1. 在同一视频/同一 Token 几何下分别测外观 Top-K、候选权重和真实运动跟踪误差；取得 MC 可读的世界位置/深度/实例真值或少量人工可复核标注。没有真值时网页框“看着对”无法校准概率。
2. 用真实 VACE 的 VAE latent、条件分支 hidden、指定主干层 Q/K 分别做相似度与可重复性对照；不能把普通视频自注意力里高噪声的首帧 $\times$ Token 当作干净参考图特征。
3. 处理候选歧义：双向匹配、循环一致性、首/尾一致性、遮挡/不可见独立输出、候选多峰而非强迫唯一对应；尤其对纯色天空，不应把“附近的漂亮框”当唯一物理对应。
4. 运动模型从全帧固定 6 个 **translation/scale** 扩展到可按证据增减的背景/深度层/局部仿射或相机补偿模型，同时设置无匹配分支；空间先验只在足够证据时启用。
5. 在生成场景重新定义**可在线获得**的时间先验，不能用真实未来视频相邻帧的 DIS 光流；最后再考虑以候选分布指导 VACE 的某层注意力，仍需允许当前帧自身/近邻/全局必要信息。

这些是待设计和测量的方向，本文没有改任何参数或实现。